

# 相位回復新求解器文獻盤點與 NP 對外比較策略

## 研究範圍與核心判斷

近兩三年的相位回復文獻，已經很清楚地分成幾條路線：傳統迭代與理論方法、深度去雜訊/plug-and-play 類方法、單樣本或無訓練先驗方法、以及擴散模型驅動的求解器。2023 年的 tutorial 把 phase retrieval 放在一個統一框架中，明確指出 classical optimization、deep regularization、以及 machine-learning-based reconstruction 應該被分開看；2024 年的深度學習回顧文則進一步把 DL 在 phase recovery 中的角色分成 pre-processing、in-processing、post-processing 三層。這對你現在很重要，因為 NP 要被包裝成什麼，取決於你想跟哪一條文獻線正面比較。<sup>1</sup>

我先講結論：如果 NP 是**不需要大規模 task-specific training**的求解器，那它最合理、也最能被社群接受的第一波對外比較，不是先去碰所有 endpoint-trained 的最新模型，而是先在一個**重複被多篇論文使用、同時有品質與 runtime 報告**的 solver benchmark 上，證明它比近期強基線更好；最合適的就是 236 張  $256 \times 256$  oversampled Fourier benchmark 這一條線。這條線已經被 2025 的 PnP-HIO、I2I-PR、prNet 連續使用，而且都報了平均 PSNR/SSIM 與單張 runtime。<sup>2</sup>

同時，也不能忽略另一個更強、但更難的現實：2025 年的資料驅動 stochastic-refinement 類方法，已經把這個 benchmark 的平均 PSNR 推到非常高，而且 inference 速度很快。換句話說，**如果你要講的是「整體 SOTA 新求解器」**，那你最終不能只打敗 HIO / prDeep / DIR / PnP-HIO，還要有辦法對 I2I-PR，甚至 prNet 這類新方法提出有說服力的挑戰；**但如果你願意把 claim 收斂成「training-free stochastic solver」或「sampling-based robust solver」**，那只要穩定壓過近期的 prior-based/solver-based 強基線，仍然完全有機會成立。<sup>3</sup>

## 近期求解器版圖

### 傳統迭代、PnP、與去雜訊先驗

傳統 solver 的核心仍然是 HIO、ER、RAAR、OSS 這些 alternating-projection 類方法；它們便宜、實作簡單、而且在很多實驗系統裡仍然是 workhorse，但容易卡住 local minima，也很吃 initialization。這點在 tutorial 與後續神經網路方法論文中都被反覆強調。<sup>4</sup>

一條很重要的 modern baseline 線，是把 image denoiser 當成先驗塞回 classical solver。2020 年的 When Deep Denoising Meets Iterative Phase Retrieval 把 RED/denoiser prior 放進 Fourier phase retrieval，作者在他們自己的 benchmark 上報告：在 random initialization 下，Deep-ITA 類方法明顯優於 HIO、OSS、prDeep 與 DnCNN-ADMM；在 HIO initialization 下，於較高雜訊水準時也持續優於 prDeep 與其他比較法。這篇論文的意義，不只是數字，而是它把「deep prior 應該作為 iterative solver 的一部分，而不是整個 end-to-end 黑箱」這件事講清楚了。<sup>5</sup>

2025 年發表於 Applied Optics<sup>6</sup> 的 Deep Plug-and-Play HIO Approach for Phase Retrieval，則是近年 solver-paper 路線裡非常實際的一個代表。它在 236 張測試圖、5 次 Monte Carlo、 $\alpha=3$  的設定下，報告 PnP-HIO 平均 25.26 dB、248 秒，優於 HIO 的 19.79 dB / 163 秒、prDeep 的 24.22 dB / 470 秒，以及 iterative DNN-HIO 的 24.54 dB / 178 秒；作者還另外用  $236 \times 5$  的 histogram 分析 initialization robustness。這類文章很接近你現在 NP 的定位，因為它講的是「solver robustness 與 solver quality」，而不是一個純 feed-forward predictor。<sup>7</sup>

## 單樣本、無訓練、與隱式生成先驗

如果你想讓 NP 走「不用 task-specific training」這條路，這條文獻線一定要讀。2023 年的 Practical Phase Retrieval Using Double Deep Image Priors 明確針對 far-field practical phase retrieval，主張單一 DIP 已經有競爭力，而雙 DIP 進一步在 realistic crystal 資料上大幅勝過 HES 與單 DIP，且不需要訓練集。它的定位不是 natural-image oversampled Fourier benchmark，而是更接近科學影像/實務相位回復。<sup>8</sup>

2024 年的 Low-light phase retrieval with implicit generative priors 則把「無訓練單樣本先驗」推到低光子 low-dose 相位回復。LoDIP 在 800 Np/px 的低解析 set 上報 28.52 dB，明顯優於 HIO-stat 的 21.55 dB 與 GPS 的 22.96 dB；到了更難的 80 Np/px，LoDIP 仍有 25.09 dB，而 HIO-stat 與 GPS 分別只有 13.11 dB、13.91 dB。對 biological cell sample，LoDIP 也在 800 與 80 Np/px 下全面優於 HIO-stat 與 GPS。這條線很有價值，但它依賴的是帶 **static reference** 的 **low-dose** 物理設定，所以不適合作為 NP 的第一個外部 benchmark，除非你準備同時講科學影像的量測設計故事。<sup>9</sup>

還有一些無訓練方法比較偏近場或特定成像設定。Net-ADM 透過 untrained generative prior + ADMM，在 MNIST/CelebA/Cameraman 的 Fourier phase retrieval 上，特別是在低 sampling-rate 區間，平均 PSNR/SSIM 往往優於 ADMM、Net-GD、Net-PGD；作者明確指出當  $r < 1.7$  時優勢特別明顯。2024 年發表於 Journal of the Optical Society of America A<sup>10</sup> 的 Res-U2Net 則是另一條近場/phase-imaging 路線的 untrained deep learning baseline，主要在 GDXRAY 測試。這些都說明：「無訓練先驗」本身不是冷門方向，但 benchmark 與 measurement model 差異很大，不能跟 oversampled Fourier natural-image solver paper 直接混成同一張表。<sup>11</sup>

## 擴散模型驅動的求解器

擴散模型路線裡，最值得你現在直接看的是三篇：DiffFPR、DDRM-PR、I2I-PR，再加上最新的 prNet。它們剛好構成了「task-agnostic pretrained prior → refinement diffusion → data-driven stochastic solver」的完整演進。<sup>12</sup>

2024 年在 ICML<sup>13</sup> 發表的 DiffFPR，是 oversampled Fourier color-image retrieval 上很重要的一篇。它在 FFHQ / ImageNet 的 1K dataset 上，對  $4\times$  oversampling 的 color Fourier phase retrieval 報告：無噪聲時 FFHQ / ImageNet 分別為 37.24 / 31.76 dB； $\sigma_y = 0.01$  時為 29.17 / 25.94 dB；單張 runtime 為 1.089 / 4.482 秒。更重要的是，作者還報了 success rate：在 1K 影像上，PSNR 超過 20 dB 的比例，DiffFPR 為 100%，RAAR 為 52.4% / 48.2%，DPS 只有 14.5% / 4.0%。這篇很適合當 **NP 對外的第二個 benchmark**，因為它是獨立團隊、顏色自然圖像、速度與成功率都有報。<sup>14</sup>

2025 年的 DDRM-PR 代表另一種擴散思路：不重新訓練 phase-retrieval-specific diffusion model，而是把 pretrained unconditional diffusion prior 配上 alternating projection。它在 CelebA-HQ 模擬資料上，相對 HIO 的提升是存在但偏溫和；但在 scattering-media 實驗資料上，PSNR 從 7.85 拉到 13.12、SSIM 從 0.049 拉到 0.32，說明 diffusion prior 在實驗型相位回復上確實有價值，只是 distortion-level 的提升沒有 DiffFPR 或後來 I2I/prNet 那麼大。這篇對你最大的啟示是：「使用 diffusion prior」本身不等於一定會贏，關鍵在於 **consistency 注入的位置與方式**。<sup>15</sup>

2025/2026 的 I2I-PR 則非常接近你現在最該比較的文獻。它不是從純 noise 生成，而是先做 classical initialization，再用 image-to-image diffusion refinement。作者在 236 張測試圖、5 次 Monte Carlo、 $\alpha=3$  的設定下，報告 I2I-PR 平均 26.78 dB、1.11 秒；同表中的 HIO、prDeep、DIR、PnP-HIO 分別為 18.92 dB / 0.27 秒、22.06 dB / 59.41 秒、22.87 dB / 21.72 秒、23.92 dB / 24.35 秒。作者還清楚寫出：訓練使用 44,000 張自然圖，單張 A100 80GB GPU 上訓練約 60 小時。這對你很關鍵，因為它同時給了你一套完整 benchmark protocol、quality、runtime、以及 offline training cost。<sup>16</sup>

更新到 2025 的 prNet: Data-Driven Phase Retrieval via Stochastic Refinement，則把同一條 236-image benchmark 再往前推。作者同樣用 44,000 張自然圖訓練，在單張 A100 80GB 上，prNet-Small / Large / Large-Adversarial 的離線訓練分別約四天、五天、一天；在測試時， $\alpha=2$  的 236-image benchmark 上，prNet-Large-Adversarial(+TTA) 報告 32.66 dB、1.80 秒，(+TTA D4) 到 32.92 dB、3.12 秒，而且作者明言在  $\alpha=2,3,4$  全部都穩定優於 HIO / prDeep / DIR / MBwDDP。這代表最新 bar 已經不只是「比 PnP-HIO 好」，而是「在同 benchmark 上大幅超越整條舊 solver ladder」。<sup>17</sup>

## 文獻實際怎麼評估

你前面擔心「大家只看 best-of-10」，這件事在某些影像生成或重建社群確實常見；但**在你現在最貼近的 oversampled-Fourier solver 文獻裡，平均值、分布、穩定性、與 runtime 並不是次等指標，反而是主指標**。I2I-PR 的主表就是「236 張圖、5 次 Monte Carlo 的 average PSNR/SSIM/runtime」；PnP-HIO 的主表也是平均值，外加 histogram 檢查對 initialization 的敏感度；prNet 甚至把  $236 \times 5$  的 PSNR/SSIM histogram 畫出來，明確把隨機初始化穩定性當成賣點；DiffFPR 在 1K dataset 上除了平均數，還補 success-rate。這些都表示：在 solver-paper 子文獻裡，**robustness across initializations 本身就是結果，不只是附錄**。<sup>18</sup>

也因此，如果 NP 的強項是把差的 reconstruction 拉回來、讓 distribution 變窄、讓 median/mean 上升，而 best-of-10 只小幅變動，這種結果**不是不能發**；問題只是你要把 paper 定位成什麼。如果你寫成「新 solver 在多初始化下更穩、更可靠、更少 catastrophic failure」，那平均值、histogram、success-rate 都是合格敘事；如果你硬寫成「最高峰值品質全面 SOTA」，那審稿人自然會盯 best-of-k 或 cherry-picked samples。這個差別，不是數據本身值不值錢，而是論文 title 與 claim 的對齊程度。<sup>19</sup>

另一個非常重要的文獻現象，是 **paper-to-paper 的表格不能直接拿來當公平排名**。最好的例子就是 PnP-HIO：原始 2025 論文在  $\alpha=3$  報 25.26 dB、248 秒；但 I2I-PR 與 prNet 在看似同一個 236-image 協議下，對同名/同族 baseline 報的是 23.92 dB、24.35 秒。這幾乎可以確定是 initialization、迭代配置、實作、或 runtime 計法不同所造成。對你來說，這不是壞消息，反而是好消息：它代表你**不需要用 paper table 硬吃所有 published numbers**，而是應該挑一個 protocol 自己 reproduce，再用你自己的 runtime-matched 規則重做比較。<sup>2</sup>

## 最值得拿來跟 NP 比的外部工作

如果你現在要選一篇**最值得做的 recent external comparison**，我會推薦 **I2I-PR**。理由不是它一定最強，而是它最適合做第一個「可交付、可說服」的對外 benchmark：它的 measurement model 就是你熟悉的 oversampled Fourier phase retrieval；它把 HIO、prDeep、DIR、PnP-HIO 全放在同一張表；它同時給 average quality 與 runtime；它又明確揭露 offline training cost。你如果能在這個 protocol 上，用「NP strongest realistic runtime」去做 matched comparison，結果會很有說服力。<sup>20</sup>

如果你想要第二個、而且更偏「獨立團隊 + 顏色自然圖像 + 成功率」的 benchmark，我會推薦 **DiffFPR**。它的 FFHQ / ImageNet 1K dataset 很適合回答另一個問題：NP 的表現是不是只在你熟悉的 236-image 灰階/自然圖 setting 成立，還是到了 color image / 1K-sample / success-rate 規模仍然站得住腳。這一條 benchmark 不是 I2I/prNet 那條團隊內部沿用的自然圖 small benchmark，因此更適合做「跨團隊、跨資料集」的外部驗證。<sup>21</sup>

如果你要追求**最強、最新的 external bar**，那就不能不看 **prNet**。但我會把它定義成「第二階段壓力測試」，不是第一槍。因為它是 2025 preprint / workshop 線上的 very recent trained solver，離線成本高，還有 adversarial 與 TTA 版本；你若一開始就拿它當唯一外部標準，風險是把整個 paper 成敗綁在最難的對手。更合理的路線是：先證明 NP 在 I2I-PR protocol 上穩定打贏 reproduced PnP-HIO / DIR / prDeep，然後再看與 I2I-PR 的 gap 有多大；如果結果很好，再往 prNet 前進。<sup>22</sup>

至於 LoDIP、Double-DIP、Res-U2Net、PhaseGAN、DeepPhaseCut 這些方法，我認為它們比較適合作為**文獻版圖與定位說明**，而不是你現在的第一輪硬比較對象。原因不是它們不重要，而是它們多數對應不同的 measurement model、不同的應用 domain、或不同的 supervision/setup 假設。把它們放進 related work 很好，但直接拉進你下一輪最關鍵的 external benchmark，反而容易讓故事分散。<sup>23</sup>

## 對 NP 新求解器路線的判斷

如果你的目標是「NP 是一個新的 solver family」，我認為這條路還沒有死，但前提是你要把勝負條件定得正確。對一個不依賴大量 task-specific training 的方法而言，最合理的最低門檻，不是直接宣稱「全面超過所有 2025 learned stochastic solver」，而是先在一個社群熟悉、可重複的 benchmark 上，**明確打贏強傳統/強 prior-based solver**。對你而言，這個最低門檻就是 reproduced PnP-HIO、DIR、prDeep 這一梯，最好再加上 I2I-PR 作為更強的 trained reference。<sup>24</sup>

更直接地說：如果 NP 在 236-image protocol 上，連 DIR / PnP-HIO 這種 20–25 秒級別的近期強基線都沒有穩定優勢，那「新 solver」故事會非常危險；如果它穩定贏這一梯、而且在允許較長 runtime 的情況下能逼近甚至超過 I2I-PR 的平均品質，那就很有機會成立為一篇 **training-free stochastic solver** 或 **robust solver** 論文。相反地，如果你希望做的是「broad SOTA solver across recent methods」，那你最終一定得面對 prNet/類 prNet 這種新 bar；若差距很大，paper 就不該這樣包裝。<sup>25</sup>

因此，我的具體判斷是：**若 NP 無法打到 prNet，那不代表新求解器方向必死；但若 NP 無法穩定壓過 reproduced PnP-HIO / DIR / prDeep，或在 I2I-PR benchmark 上連接近都做不到，那 broad new-solver claim 就應該收斂**。這時比較合理的改寫方向，是把 novelty 放在「sampling-based search、robustness、deferred consistency、或多重重建穩定性」上，而不是「全面最強 phase-retrieval solver」。這樣的 claim 與目前 literature 的評估習慣其實是對齊的。<sup>26</sup>

## 限制與未決問題

目前這份盤點有三個要特別保留的限制。第一，**不同論文之間即使看起來用了相同 benchmark，實際 protocol 也可能不完全相同**；PnP-HIO 在原始論文與後續 I2I/prNet 表格的巨大差距，就是最直接的例子。第二，**近兩年的最強結果很多來自 task-specific trained solver**；如果你想讓 NP 以 training-free 身分跟它們公平比較，必須在論文裡明確區分「offline training cost」與「test-time runtime」。I2I-PR 約 60 小時 training、prNet 約 1–5 天 training，這些都是不能忽略的比較條件。第三，**我這裡沒有把每一篇應用導向 phase imaging/holography/deep unfolding 論文都展開做 benchmark extraction**；那些工作適合寫完整 related work，但不一定適合作為你下一步最關鍵的外部對手。<sup>27</sup>

綜合以上，若你現在只能做一組外部比較，我的建議很明確：先做 **I2I-PR 的 236-image protocol**；若還有第二組，再做 **DiffFPR 的 FFHQ/ImageNet 1K protocol**。前者回答「NP 能不能成為有說服力的新 solver」；後者回答「NP 能不能跨團隊、跨資料集地站住腳」。若這兩關都過，再談 prNet 級別的最強比較，會是更穩的路線。<sup>28</sup>

---

<sup>1</sup> <sup>4</sup> <sup>6</sup> <https://arxiv.org/abs/2204.03554>

<https://arxiv.org/abs/2204.03554>

<sup>2</sup> <sup>7</sup> <sup>10</sup> <sup>13</sup> <sup>19</sup> <sup>26</sup> <sup>27</sup> <https://open.metu.edu.tr/bitstream/handle/11511/113723/index.pdf>

<https://open.metu.edu.tr/bitstream/handle/11511/113723/index.pdf>

<sup>3</sup> <sup>16</sup> <sup>18</sup> <sup>20</sup> <sup>24</sup> <sup>25</sup> <sup>28</sup> <https://arxiv.org/pdf/2507.09609>

<https://arxiv.org/pdf/2507.09609>

5 <https://proceedings.mlr.press/v119/wang20r/wang20r.pdf>

<https://proceedings.mlr.press/v119/wang20r/wang20r.pdf>

8 <https://arxiv.org/pdf/2211.00799>

<https://arxiv.org/pdf/2211.00799>

9 23 [https://ww3.math.ucla.edu/wp-content/uploads/2024/08/Low\\_light\\_phase\\_retrieval.pdf](https://ww3.math.ucla.edu/wp-content/uploads/2024/08/Low_light_phase_retrieval.pdf)

[https://ww3.math.ucla.edu/wp-content/uploads/2024/08/Low\\_light\\_phase\\_retrieval.pdf](https://ww3.math.ucla.edu/wp-content/uploads/2024/08/Low_light_phase_retrieval.pdf)

11 <https://arxiv.org/pdf/2210.12646>

<https://arxiv.org/pdf/2210.12646>

12 14 21 <https://openreview.net/pdf?id=7E4c2gyP0R>

<https://openreview.net/pdf?id=7E4c2gyP0R>

15 <https://ar5iv.org/pdf/2501.03030>

<https://ar5iv.org/pdf/2501.03030>

17 22 <https://arxiv.org/pdf/2507.09608>

<https://arxiv.org/pdf/2507.09608>